

Отчёт по проекту: Применение метода Mixture-of-Channels для эффективного обучения LLM с длинным контекстом

Команда проекта: Бурмистрова Екатерина, Пуртова Ксения

10 апреля 2026 г.

Аннотация

В данном проекте исследуется применение метода Mixture-of-Channels (MoC) для снижения потребления памяти при обучении больших языковых моделей (LLM) на длинных контекстах. Метод основан на спарсификации активаций в FFN-слоях, что позволяет существенно сократить объём видеопамяти без значительной потери качества. В отчёте представлен текущий статус работ: выбрана модель Llama 3.2 3B, проведены первичные проверки корректности и качества генерации, реализован спарсованный прямой проход MLP. Описан план дальнейших работ, включающий разработку обратного прохода, тонкую настройку модели с длинным контекстом и абляционные исследования структурной спарсификации с оценкой через LLM Eval.

1 Введение

Современные большие языковые модели демонстрируют впечатляющие результаты, но их масштабирование приводит к огромным требованиям к памяти. Особенно остро эта проблема стоит при работе с длинными контекстами, где активации становятся критическим узким местом, даже при использовании FlashAttention [2]. Недавняя работа *Mixture-of-Channels: Exploiting Sparse FFNs for Efficient LLMs Pre-Training and Inference* [1] предлагает новый подход: в FFN-слоях активируются только Топ-К наиболее значимых каналов, что радикально сокращает объём хранимых активаций. Это открывает возможности для эффективного обучения на длинных последовательностях.

Цель нашего проекта — реализовать метод MoC, провести его эмпирическую оценку в контексте обучения с длинным контекстом и сравнить с базовой моделью по памяти и итоговым метрикам качества.

2 Используемая модель

В качестве базовой архитектуры выбрана **Llama 3.2 3B** (текстовая версия). Это модель нового поколения семейства Llama, отличающаяся оптимизированной архитектурой, групповым вниманием (GQA) и улучшенной эффективностью. Размерность скрытого состояния — 3072, количество слоёв — 28, промежуточный размер FFN — 8192. Модель предварительно обучена на больших объёмах текстовых данных и поддерживает работу с длинными последовательностями (до 128k токенов). В том же релизе представлена мультимодальная версия, однако в рамках данного проекта используется только текстовая модификация.

Выбор этой модели обусловлен её современной архитектурой, небольшим размером (один из критериев заключался в том, чтобы ее можно было запускать на одном девайсе mps (apple silicon GPU) локально) и за счет него высокой скоростью проведения экспериментов. На финальных этапах работы также планируется повторение проделанных работ к еще более миниатюрной текстовой модели из того же релиза - Llama3.2 1B, к весам которой тоже удалось получить доступ.

3 Используемые датасеты

Для оценки качества моделей используются датасеты из популярного и широко используемого в научных публикациях бенчмарка LM Evaluation Harness: arc_challenge, arc_easy, hellaswag, boolq, wikitext, winogrande.

4 Текущий статус экспериментальных работ

На данный момент выполнен первый этап проекта, включающий:

- **Софтверная реализация спарсификации MLP (forward pass):** Разработан модуль, заменяющий стандартный FFN-блок Llama на спарсованную версию согласно принципам Mixture-of-Channels. В прямом проходе для каждого токена активируются только Топ-К каналов в промежуточном слое SwiGLU, что позволяет сократить объём хранимых активаций.
- **Проверка корректности (sanity check):** Выполнены тесты для подтверждения того, что спарсованный forward возвращает численно корректные выходы (сравнение с эталонной реализацией при полной активации всех каналов) - i.e. те, которые декодируются в адекватный текст при минимальном уровне спарсификации потенциально нечувствительных слоев модели.
- **Оценка качества на части датасетов из LM Eval:** Проведена проверка качества на части датасетов из бенчмарка LM Eval: hellaswag, arc_easy, arc_challenge при спарсификации только MLP блока из 10 слоя.

Таблица 1: Сравнение качества в Lm-Eval бенчмарках

Task	Original	MLP in layer 10 is sparsed
HellaSwag (acc, %)	49.0	48.0
ArcEasy (acc, %)	76.0	72.0
ArcChallenge (acc, %)	42.0	36.0
BoolQ (acc, %)	76.0	77.0
Winogrande (acc, %)	71.0	70.0
Wikitext (perplexity, x)	9.51	10.232

4.1 Планируемые расширения

1. **Реализация обратного прохода (backward pass) - софтверно:** Поддержка спарсификации градиентов во время fine-tuning.

2. **Реализация прямого прохода (forward pass):** Разработка эффективного CUDA-ядра для спарсификации активаций при инференсе и прямом проходе данных через модель.
3. **Реализация обратного прохода (backward pass):** Разработка эффективного CUDA-ядра для обратного распространения ошибки через разреженные активации с сохранением градиентов только для выбранных каналов. Это необходимо для полной поддержки обучения (fine-tuning).
4. **Тонкая настройка (fine-tuning) на длинном контексте:** Обучение модели с использованием спарсификации и без неё на задачах с длинными входными последовательностями (например, суммаризация длинных документов, ответы на вопросы по нескольким источникам). С использованием LoRA адаптеров.
5. **Абляционные исследования структурной спарсификации:**
 - Варьирование параметра k в классическом сеттинге TopK спарсификации.
 - Варьирование стратегии выбора каналов: вместо глобального Top-K по всему FFN, исследовать группировку каналов и выбор Top-K внутри каждой группы (структурная спарсификация, удобная для аппаратной оптимизации).
 - Изучение влияния количества и расположения спарсифицируемых слоёв: спарсифицировать все FFN-слои, только первые/последние, или чередовать.
6. **Оценка с использованием LLM Eval:** Все метрики качества (перплексия, точность на downstream задачах, BLEU/ROUGE для генеративных задач) будут собираться через бенчмарк LLM Eval, что обеспечит стандартизированное и воспроизводимое сравнение.

5 План выполнения всего проекта

Ниже представлен детальный план работ с разбивкой по этапам и срокам.

Таблица 2: План-график выполнения проекта

Этап	Описание работ
1. Разработка ядер (продолжение)	Написание CUDA-ядер для backward pass спарсифицированного MLP. Интеграция в PyTorch через C++ extension. Проверка корректности градиентов.
2. Настройка fine-tuning	Подготовка скриптов для тонкой настройки Llama 3.2 3B на длинных контекстах. Выбор датасетов (например, части SlimPajama с увеличенной длиной, LongBench).
3. Абляционные эксперименты	Проведение серии запусков с разными конфигурациями спарсификации: варьирование Top-K, группировка каналов, выбор слоёв. Сбор метрик памяти и времени.
4. Оценка качества	Использование LLM Eval для вычисления целевых метрик (перплексия, точность на задаче MMLU, ROUGE на суммаризации, и т.д.). Сравнение с базовой моделью.
5. Анализ и отчётность	Статистическая обработка результатов, подготовка итогового отчёта (LaTeX) и выкладка кода в открытый репозиторий.

Ориентировочные сроки: 4–6 недель с учётом итераций по оптимизации.

6 Состав команды

- **Бурмистрова Екатерина** — ответственный за разработку CUDA-ядер (forward/backward), интеграцию в PyTorch, проведение абляционных исследований, взаимодействие с LLM Eval.
- **Пуртова Ксения** — анализ данных, проведение fine-tuning, настройка экспериментов, сбор метрик памяти и времени, подготовка отчёта.

7 Заключение

На текущий момент заложена основа проекта: выбрана релевантная модель (Llama 3.2 3B), реализован спарсованный прямой проход MLP, проведены первичные проверки корректности и качества. Следующим шагом станет разработка обратного прохода и переход к полномасштабному fine-tuning с длинным контекстом. Абляционные исследования позволят выявить оптимальные стратегии спарсификации, а использование LLM Eval обеспечит объективную оценку качества. Полученные результаты могут быть полезны для сообщества как пример эффективного применения структурной разреженности при работе с длинными последовательностями.

Список литературы

- [1] Tong Wu, Yutong He, et al. *Mixture-of-Channels: Exploiting Sparse FFNs for Efficient LLMs Pre-Training and Inference*. arXiv preprint arXiv:2511.09323, 2025.

- [2] Tri Dao, Daniel Y. Fu, et al. *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness*. In NeurIPS, 2022.
- [3] Meta AI. *Llama 3.2: A New Generation of Open Language Models*. <https://ai.meta.com/blog/llama-3-2/>, 2024.
- [4] EleutherAI. *Language Model Evaluation Harness (LLM Eval)*. <https://github.com/EleutherAI/lm-evaluation-harness>.